

Evaluasi Komparatif Teknik Penskalaan Fitur pada Berbagai Klasifikator dan Domain

Amri Reza Wahyudin^{1*}, Sri Murdiawati², Juan Adi Putra³, Erliyan Redy Susanto⁴

^{1,2,3,4}Magister Ilmu Komputer, Fakultas Teknik dan Ilmu Komputer,

Universitas Teknokrat Indonesia

*Penulis korespondensi: amri_reza_wahyudin@teknokrat.ac.id

Abstrak

Penskalaan fitur sangat krusial pada algoritma *machine learning* berbasis jarak, namun teknik optimal pada berbagai klasifikator, domain, dan tipe permasalahan belum diketahui secara pasti. Studi ini mengevaluasi enam konfigurasi penskalaan—Normalisasi *Min-Max*, Standardisasi *Z-Score*, *Robust Scaling* (IQR), *MaxAbs Scaling*, dan *Quantile Transformation*—dibandingkan dengan *baseline* data mentah pada enam *dataset* standar dan tujuh klasifikator (*k-NN* dengan jarak Euclidean, Manhattan, dan Cosine; *SVM* dengan kernel Linear dan RBF; *Decision Tree*; dan *Random Forest*), termasuk empat *dataset* multikelas (3–10 kelas). Sebanyak 3.384 konfigurasi dievaluasi menggunakan validasi silang bertingkat 5-lipat. Standardisasi *Z-Score* menempati peringkat pertama (0,8561), diikuti *Min-Max* (0,8530, $p = 0,123$ —setara secara statistik) dan *MaxAbs* (0,8506). Pemilihan *scaler* optimal bergantung pada domain: *Z-Score* unggul pada data medis dan biologis multikelas, *Min-Max* pada ruang fitur terbatas, *MaxAbs* pada data berdimensi tinggi, dan data mentah memadai ketika fitur telah berskala alami. Klasifikator berbasis jarak meningkat 4,5–7,7% dengan penskalaan, sementara model berbasis pohon hampir invarian ($<0,2\%$). Hasil ini memberikan acuan praktis bagi pengambilan keputusan prapemrosesan dalam tugas klasifikasi. Kode sumber dan implementasi lengkap eksperimen ini tersedia secara terbuka pada repositori <https://github.com/AmZaDin14/feature-scaling-study>.

Kata kunci: penskalaan fitur, normalisasi, standardisasi, *robust scaling*, *MaxAbs*, *QuantileTransformer*, *k-nearest neighbors*, *SVM*, klasifikasi multikelas, studi komparatif

1 Pendahuluan

Algoritma *k-Nearest Neighbors* (*k-NN*) banyak digunakan dalam tugas klasifikasi [1, 2], yang beroperasi berdasarkan prinsip kedekatan dalam ruang multidimensi [3, 4]. Akan tetapi,

⁰Kode dan data: <https://github.com/AmZaDin14/feature-scaling-study>

efektivitas k -NN—dan seluruh klasifikator berbasis jarak—sangat bergantung pada skala fitur. Pada *dataset* empiris, fitur-fitur seringkali memiliki satuan dan rentang nilai yang sangat berbeda, seperti usia (0–100) dibandingkan penghasilan (0– 10^6). Hal ini menimbulkan masalah fundamental: fitur dengan magnitudo lebih besar secara matematis akan mendominasi perhitungan jarak tanpa memandang signifikansi prediktifnya [5, 6, 7].

Support Vector Machines (SVM) juga sensitif terhadap skala fitur [8, 9]. Regularisasi memberikan penalti secara seragam pada koefisien, sehingga fitur tak terskala dengan rentang lebih besar menerima bobot yang lebih kecil secara tidak proporsional. Model berbasis pohon (*Decision Tree*, *Random Forest*) secara teoretis bersifat invarian terhadap penskalaan [10], karena pohon keputusan melakukan pemisahan berdasarkan ambang batas per fitur secara independen.

Meskipun pentingnya penskalaan fitur telah diketahui secara luas, literatur ilmiah masih kekurangan tolok ukur komprehensif yang secara simultan membandingkan beberapa teknik penskalaan pada beberapa famili klasifikator, baik pada permasalahan biner maupun multikelas. Studi yang ada cenderung membatasi perbandingan pada *Min-Max* versus *Z-Score* pada satu algoritma [11, 12], atau mengevaluasi satu teknik pada beberapa algoritma [7]. Belum ada studi sebelumnya yang secara sistematis membandingkan enam teknik penskalaan—termasuk *MaxAbs Scaling* dan *Quantile Transformation*—pada tujuh klasifikator di *dataset* biner dan multikelas dengan validasi statistik.

Studi ini menjawab celah-celah tersebut melalui tiga pertanyaan penelitian:

- RQ1:** Teknik penskalaan manakah yang menghasilkan kinerja klasifikasi keseluruhan terbaik pada pengaturan biner maupun multikelas?
- RQ2:** Apakah teknik penskalaan optimal bergantung pada jenis klasifikator yang digunakan?
- RQ3:** Apakah teknik penskalaan optimal bergantung pada domain data dan tipe permasalahan (biner vs. multikelas)?

Kami juga memperkenalkan *MaxAbs Scaling* dan *Quantile Transformation*—teknik yang tersedia di pustaka standar namun jarang diukurbandingkan terhadap *Min-Max*, *Z-Score*, dan *Robust Scaling* dalam kerangka komparatif terpadu.

2 Penelitian Terkait

2.1 Dasar-Dasar Penskalaan Fitur

Penskalaan fitur mentransformasikan rentang numerik fitur ke suatu skala yang seragam. Lima pendekatan utama dievaluasi dalam studi ini, yang didefinisikan oleh Persamaan (1) hingga (6).

Jarak Euclidean merupakan metrik yang mendasari sebagian besar klasifikator berbasis jarak. Diberikan dua titik data $\mathbf{x}$ dan $\mathbf{y}$ dalam ruang n -dimensi, jaraknya adalah:

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (1)$$

Tanpa penskalaan fitur, fitur dengan magnitudo lebih besar mendominasi penjumlahan ini secara tidak proporsional.

Normalisasi Min-Max menskala ulang fitur secara linear ke rentang tetap, umumnya $[0, 1]$:

$$x_{\text{norm}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (2)$$

Metode ini mempertahankan bentuk distribusi asli namun sensitif terhadap pencilan (*outliers*), karena nilai ekstrem akan memampatkan data lainnya ke dalam sub-rentang yang sempit.

Standardisasi Z-Score memusatkan fitur ke rata-rata nol dan varians satuan:

$$x_{\text{std}} = \frac{x - \mu}{\sigma} \quad (3)$$

Berbeda dengan *Min-Max*, *Z-Score* tidak membatasi nilai ke rentang tetap, sehingga lebih kokoh terhadap pencilan sambil mempertahankan informasi jarak relatif.

Robust Scaling menggunakan median dan rentang interkuartil (IQR):

$$x_{\text{robust}} = \frac{x - \text{median}(x)}{\text{IQR}(x)} \quad (4)$$

Dengan menggunakan statistik yang kokoh, metode ini menjadi yang paling tangguh terhadap pencilan [13].

MaxAbs Scaling menskala setiap fitur berdasarkan nilai absolut maksimumnya, memetakan ke rentang $[-1, 1]$:

$$x_{\text{maxabs}} = \frac{x}{\max(|x|)} \quad (5)$$

Metode ini mempertahankan *sparsity* (nilai nol tetap nol) dan umum digunakan untuk data jarang (*sparse data*).

Quantile Transformation memetakan setiap fitur ke distribusi seragam atau normal melalui invers fungsi distribusi kumulatif empiris:

$$x_{\text{quantile}} = F_{\text{uniform}}^{-1}(F_{\text{empirical}}(x)) \quad (6)$$

Berbeda dengan metode linear di atas, *Quantile Transformation* bersifat non-linear dan dapat menangani distribusi arbitrer [14].

Tabel 1 merangkum keenam teknik tersebut.

Table 1: Ringkasan teknik penskalaan fitur.

Teknik	Formula	Rentang	Linearitas
Min-Max	Pers. (2)	$[0, 1]$	Linear
Z-Score	Pers. (3)	Tak terbatas	Linear
Robust	Pers. (4)	Tak terbatas	Linear
MaxAbs	Pers. (5)	$[-1, 1]$	Linear
Quantile	Pers. (6)	$(0, 1)$	Non-linear

2.2 Studi Komparatif Sebelumnya

Pagan dkk. [7] meneliti *Min-Max*, *Z-Score*, dan *decimal scaling* pada *k-NN* di sepuluh *dataset*, dan menemukan bahwa pemilihan teknik penskalaan secara signifikan memengaruhi kinerja namun bervariasi antar *dataset*. Henderi dkk. [11] membandingkan *Min-Max* dan *Z-Score* pada *k-NN* untuk klasifikasi kanker payudara, melaporkan keunggulan *Min-Max* (98% vs 97%). Firmansyah dan Astuti [15] membandingkan standarisasi dan normalisasi pada *k-NN* untuk klasifikasi stroke. Pinheiro dkk. [9] baru-baru ini melakukan studi skala besar terhadap 12 *scaler* pada 14 algoritma di 16 *dataset*, yang menunjukkan bahwa metode ensemble kokoh terhadap penskalaan sementara SVM sangat sensitif.

Akan tetapi, studi-studi ini memiliki keterbatasan yang serupa: perbandingan terbatas pada satu klasifikator (*k-NN*), jarang menyertakan *MaxAbs* atau *Quantile Scaling*, dan seringkali tidak menyertakan evaluasi multikelas. Studi kami menjawab keterbatasan ini dengan memperluas perbandingan ke tujuh klasifikator, enam *scaler* (termasuk *MaxAbs* dan *Quantile*), dan enam *dataset* yang mencakup permasalahan biner maupun multikelas, dengan validasi statistik melalui uji peringkat-bertanda *Wilcoxon* berpasangan.

3 Metodologi

3.1 Dataset

Enam *dataset* klasifikasi standar dipilih untuk merepresentasikan beragam domain dan tipe permasalahan. Tabel 2 merangkum karakteristiknya. Empat dari enam *dataset* bersifat multikelas (3–10 kelas), memungkinkan evaluasi efek penskalaan di luar pengaturan biner.

Pima Indians Diabetes mengandung nilai nol yang tidak valid secara biologis pada fitur seperti Glukosa dan BMI, yang diimputasi menggunakan median (sejalan dengan [16]). Semua *dataset* lainnya digunakan dalam bentuk aslinya—Wine dan Digits sebagai permasalahan multikelas (masing-masing 3 dan 10 kelas), serta Yeast dan Segment sebagaimana publikasi aslinya.

Table 2: Karakteristik *dataset*.

Dataset	Domain	Sampel	Fitur	Kelas
Pima Indians Diabetes	Medis	768	8	2
Breast Cancer Wisconsin	Medis	569	30	2
Wine	Kimia	178	13	3
Digits	Citra	1.797	64	10
Yeast	Biologi	1.484	8	10
Segment	Segmentasi	2.310	19	7

3.2 Teknik Penskalaan

Enam konfigurasi penskalaan dievaluasi, sebagaimana dirangkum dalam Tabel 3. Seluruh *scaler* diimplementasikan melalui `scikit-learn` dengan parameter bawaan.

Table 3: Konfigurasi penskalaan yang dievaluasi.

Scaler	Tipe	Rentang	Sifat Utama
None (Mentah)	Tanpa transformasi	Asli	Baseline
Min-Max	Pers. (2)	$[0, 1]$	Mempertahankan distribusi
Z-Score	Pers. (3)	Tak terbatas	Memusatkan data
Robust	Pers. (4)	Tak terbatas	Berbasis Median/IQR
MaxAbs	Pers. (5)	$[-1, 1]$	Mempertahankan <i>sparsity</i>
Quantile	Pers. (6)	$(0, 1)$	Non-linear

3.3 Klasifikator

Tujuh klasifikator dievaluasi, sebagaimana ditunjukkan pada Tabel 4. Untuk varian *k-NN*, seluruh nilai *k* dari 1 hingga 30 diuji untuk menangkap sensitivitas terhadap ukuran tetangga. Klasifikator non-*k-NN* menggunakan parameter bawaan `scikit-learn`.

Table 4: Konfigurasi klasifikator.

No.	Klasifikator	Parameter
1	k-NN (Euclidean)	$k = 1, \dots, 30$, metrik = Euclidean
2	k-NN (Manhattan)	$k = 1, \dots, 30$, metrik = Manhattan
3	k-NN (Cosine)	$k = 1, \dots, 30$, metrik = Cosine
4	SVM (Linear)	<i>kernel</i> = linear
5	SVM (RBF)	<i>kernel</i> = rbf
6	Decision Tree	CART, bawaan
7	Random Forest	100 <i>estimator</i> , bawaan

3.4 Protokol Eksperimental

Setiap *dataset* diproses sebagai berikut:

1. **Prapemrosesan:** Nilai nol tidak valid diimputasi dengan median (khusus Pima).
2. **Validasi silang:** Pembagian bertingkat 5-lipat yang mempertahankan distribusi kelas [17].
3. **Penskalaan:** Setiap *scaler* dipasang pada lipatan pelatihan, lalu diterapkan pada lipatan pelatihan dan validasi secara independen—memastikan tidak terjadi kebocoran data.
4. **Evaluasi:** Klasifikator dilatih pada lipatan pelatihan yang telah diskala, lalu dievaluasi pada lipatan validasi yang telah diskala.
5. **Metrik:** Akurasi (rata-rata $\pm$ simpangan baku antar lipatan), presisi, *recall*, *F1-score*, AUC, spesifisitas, sensitivitas.

Untuk evaluasi multikelas, presisi, *recall*, dan *F1-score* dihitung dengan rata-rata terbobot (*weighted averaging*) untuk memperhitungkan ketidakseimbangan kelas. AUC dihitung menggunakan skema satu-lawan-sisanya (*one-vs-rest*, OvR). Sensitivitas dan spesifisitas dirata-ratakan secara makro di seluruh kelas, memberikan bobot yang sama pada setiap kelas tanpa memandang prevalensinya.

Pemilihan $k = 1, \dots, 30$ untuk k -NN mencakup rentang praktis penuh dari batas keputusan yang sangat lokal ($k = 1$) hingga hampir global ($k = 30$), menangkap rezim *overfitting* maupun *underfitting*. Klasifikator non- k -NN menggunakan hiperparameter bawaan `scikit-learn`: SVM dengan $C = 1$ dan RBF $\gamma = 1/n_{\text{fitur}}$, *Decision Tree* dengan kedalaman tak terbatas dan *Gini impurity*, serta *Random Forest* dengan 100 pohon. Nilai-nilai bawaan ini merupakan *base-line* yang mapan dalam studi ML komparatif dan menghindari pencampuran efek penskalaan dengan artefak penalaan hiperparameter, yang ditunda untuk penelitian selanjutnya.

Pemilihan validasi silang bertingkat 5-lipat menyeimbangkan bias dan varians sambil memastikan setiap lipatan mempertahankan proporsi kelas asli. Lima lipatan memberikan timbang terima yang baik antara varians tinggi dari validasi silang 2-lipat dan biaya komputasi tinggi dari validasi silang 10-lipat, dan pengambilan sampel bertingkat mencegah bias optimistik pada kelas minoritas, yang sangat krusial untuk *dataset* multikelas dengan distribusi tidak seimbang (misalnya, Yeast dengan 10 kelas).

Secara total: $6 \text{ dataset} \times 6 \text{ scaler} \times (3 \text{ varian } k\text{-NN} \times 30 \text{ nilai } k + 4 \text{ klasifikator non-}k\text{-NN}) = \mathbf{3.384 \text{ konfigurasi}}$, masing-masing dievaluasi dengan validasi silang bertingkat 5-lipat (**16.920 total pemasangan model**).

3.5 Analisis Statistik

Uji peringkat-bertanda *Wilcoxon* berpasangan [18] dilakukan untuk setiap pasangan *scaler* pada seluruh konfigurasi yang berpadanan (*dataset*, klasifikator, nilai k). Uji non-parametrik ini dipilih karena perbedaan kinerja antar *scaler* tidak dijamin mengikuti distribusi normal. Signifikansi dinilai pada $\alpha = 0,05$.

4 Hasil

4.1 RQ1: Kinerja Penskalaan Keseluruhan

Teknik penskalaan manakah yang memberikan akurasi terbaik di seluruh kondisi? Dirata-ratakan pada seluruh *dataset* dan klasifikator, keenam teknik penskalaan menunjukkan peringkat seperti pada Tabel 5.

Table 5: Peringkat *scaler* keseluruhan berdasarkan rata-rata akurasi pada validasi silang bertingkat 5-lipat.

Scaler	Rata-rata Akurasi	Simpangan Baku
Z-Score	0,8561	0,147
Min-Max	0,8530	0,150
MaxAbs	0,8506	0,151
Robust	0,8370	0,146
Quantile	0,8345	0,156
Mentah (Raw)	0,8050	0,146

Pada tingkat agregat, jawaban untuk RQ1 adalah: **Z-Score menempati peringkat pertama, namun tiga scaler teratas (Z-Score, Min-Max, MaxAbs) berada dalam kelompok yang berdekatan.** Uji peringkat-bertanda *Wilcoxon* menunjukkan:

- **Z-Score vs Min-Max:** $p = 0,123$ (tidak signifikan; secara statistik setara)
- **Z-Score vs MaxAbs:** $p = 0,002$ (signifikan, namun efek kecil: +0,0055)
- **Z-Score vs Mentah:** $p < 0,001$ (signifikan)
- **Min-Max vs MaxAbs:** $p < 0,001$ (signifikan, +0,0024)
- **Semua scaler vs Mentah:** $p < 0,01$ (semua signifikan)

Hasil agregat ini mengonfirmasi bahwa **penskalaan apa pun secara signifikan lebih baik daripada tanpa penskalaan.** Namun, selisih sempit antar pesaing teratas (hanya 0,0055 antara *Z-Score* dan *MaxAbs*) menegaskan bahwa pertanyaan praktisnya bukanlah *scaler mana yang menang secara keseluruhan* melainkan *scaler mana yang terbaik untuk data spesifik saya.*

4.2 RQ2: Pengaruh Jenis Klasifikator

Apakah teknik penskalaan optimal bergantung pada klasifikator yang digunakan? Gambar 1 dan Tabel 6 menjawab pertanyaan ini.




Figure 1: Peta panas akurasi yang menunjukkan rata-rata akurasi setiap kombinasi *scaler*–klasifikator per *dataset*. Sel yang lebih gelap menunjukkan akurasi lebih tinggi.

Table 6: Dampak penskalaan berdasarkan jenis klasifikator (rata-rata akurasi pada seluruh *dataset*).

Klasifikator	Scaler Terbaik	Akurasi Terbaik	Peningkatan
k-NN (Euclidean)	Min-Max	0,8615	+0,0602
k-NN (Manhattan)	Min-Max	0,8612	+0,0456
k-NN (Cosine)	Z-Score	0,8514	+0,0556
SVM (Linear)	Z-Score	0,8696	+0,0656
SVM (RBF)	Min-Max	0,8749	+0,0769
Decision Tree	Z-Score	0,8091	+0,0015
Random Forest	MaxAbs	0,8779	+0,0010

Tiga pola berbeda muncul:

Klasifikator berbasis jarak (*k-NN*, SVM) sangat bergantung pada penskalaan. Tanpa penskalaan, rata-rata akurasi *k-NN* turun sebesar 4,6–6,0 poin persentase. SVM dengan kernel linear bahkan lebih sensitif (penurunan 6,6 pp dengan data mentah). SVM dengan kernel RBF menunjukkan peningkatan terbesar dari penskalaan (+7,7 pp), mengindikasikan bahwa batas keputusan lokal kernel RBF memperoleh manfaat substansial dari penskalaan fitur yang tepat.

Di antara varian *k-NN*, *MaxAbs* dan *Z-Score* menghasilkan akurasi paling stabil pada seluruh

nilai k (Gambar 2). *Min-Max* menunjukkan fluktuasi tajam pada data Pima Diabetes akibat pemampatan pencilan.




Figure 2: Akurasi k -NN (Euclidean) versus k pada Pima Indians Diabetes di bawah setiap teknik penskalaan.

Klasifikator berbasis pohon (*Decision Tree*, *Random Forest*) pada dasarnya invarian terhadap penskalaan. Selisih akurasi antara data mentah dan data dengan *scaler* terbaik kurang dari 0,2 poin persentase. Hal ini sejalan dengan ekspektasi teoretis bahwa pemisahan berbasis ambang batas tidak terpengaruh oleh transformasi monotonik [10].

***MaxAbs Scaling* muncul sebagai pesaing kuat baru**, menempati peringkat terbaik untuk *Random Forest* dan kompetitif di seluruh klasifikator berbasis jarak. Berbeda dengan *Min-Max*, *MaxAbs* tidak memampatkan rentang fitur yang memiliki pencilan, sehingga lebih konsisten di berbagai *dataset*.

Pola-pola ini mengonfirmasi jawaban RQ2: **pemilihan klasifikator sangat menentukan seberapa besar pengaruh penskalaan**, dengan model berbasis jarak sangat sensitif dan model berbasis pohon bersifat kokoh.

4.3 RQ3: Pengaruh Domain Data dan Tipe Permasalahan

Apakah teknik penskalaan *terbaik* bergantung pada karakteristik data, termasuk apakah permasalahan bersifat biner atau multikelas? Tabel 7 memerinci hasil berdasarkan *dataset*.

Table 7: *Scaler* terbaik per *dataset* (rata-rata akurasi pada seluruh klasifikator).

Dataset	Tipe	Scaler Terbaik	Rata-rata Akurasi	Scaler Terburuk
Breast Cancer	Biner	Z-Score	0,9574	Mentah (0,9265)
Pima Diabetes	Biner	Z-Score	0,7472	Mentah (0,7161)
Wine	Multi(3)	Z-Score	0,9666	Mentah (0,7312)
Segment	Multi(7)	MaxAbs	0,9455	Mentah (0,9078)
Digits	Multi(10)	Mentah	0,9732	Robust (0,9070)
Yeast	Multi(10)	Z-Score	0,5765	Quantile (0,5408)

Analisis per-*dataset* mengungkapkan pola yang digerakkan oleh domain:

Pada data medis dengan pencilan (Pima, Breast Cancer), Z-Score secara konsisten unggul. Kedua *dataset* mengandung pencilan signifikan; pemusatan dan penskalaan Z-Score

mencegah fitur dengan nilai ekstrem mendominasi perhitungan jarak. Keunggulan ini terlihat pada proyeksi t -SNE (Gambar 3), di mana Z -Score menghasilkan pemisahan kluster yang paling koheren.



Figure 3: Proyeksi t -SNE Pima Indians Diabetes di bawah setiap teknik penskalaan. Merah = diabetes, biru = sehat.

Pada data kimia dengan pengukuran terbatas (Wine), Z -Score juga unggul—bertentangan dengan intuisi umum bahwa Min - Max optimal untuk data terbatas. Ketika dievaluasi sebagai permasalahan 3 kelas (vs. binerisasi pada penelitian sebelumnya), Z -Score mencapai 0,967 dibandingkan Min - Max pada 0,954, mengindikasikan bahwa batas keputusan multikelas memperoleh manfaat dari standardisasi yang mempertahankan jarak relatif di seluruh pasangan kelas secara simultan.

Pada data segmentasi citra (Segment), $MaxAbs$ mencapai skor tertinggi (0,9455), sedikit mengungguli Min - Max (0,9416). Ini adalah satu-satunya *dataset* di mana $MaxAbs$ memimpin, dan keunggulannya kemungkinan berasal dari fitur tekstur yang memiliki rentang dinamis bervariasi tanpa pencilan ekstrem.

Pada data piksel yang telah berskala alami (Digits), penskalaan memberikan manfaat minimal hingga negatif. Data mentah (0,9732) dan $MaxAbs$ (0,9728) secara virtual setara, sementara $Robust Scaling$ justru menurunkan akurasi menjadi 0,9070.

Pada data biologis multikelas (Yeast), semua *scaler* bekerja kurang memadai (0,54–0,58). Yeast memiliki 10 kelas yang sangat tidak seimbang dengan distribusi fitur yang tumpang tindih. Z -Score memimpin secara marginal (0,5765), namun akurasi absolut yang rendah mengindikasikan bahwa penskalaan saja tidak dapat mengompensasi tumpang tindih kelas yang inheren.

Jawaban untuk RQ3: Karakteristik domain sangat menentukan *scaler* mana yang bek-

erja terbaik, dan pola ini berlaku pada pengaturan biner maupun multikelas. Hasil multikelas mencerminkan temuan biner untuk *Z-Score*, mengonfirmasi bahwa keunggulannya bersifat generalisasi di luar kasus biner.

4.4 Temuan Tambahan

Interaksi metrik jarak dengan penskalaan. Untuk *k-NN*, jarak *Manhattan* dengan *scaler* yang sesuai mencapai hasil yang sebanding dengan *Euclidean*. Jarak *Cosine* bekerja kompetitif pada data berdimensi tinggi (Breast Cancer, Digits) namun menurun pada *dataset* dengan sampel kecil (Wine).

***Quantile Transformation* berada di bawah *scaler* linear.** Meskipun memiliki keunggulan teoretis dalam menangani distribusi arbitrer, *QuantileTransformer* menempati peringkat kelima secara keseluruhan. Hal ini kemungkinan disebabkan oleh sensitivitas klasifikator yang dievaluasi terhadap pemeliharaan jarak relatif, yang terdistorsi oleh transformasi non-linear.

***MaxAbs Scaling* sebagai alternatif kokoh terhadap *Min-Max*.** Di seluruh *dataset*, *MaxAbs* berada di tiga besar untuk 5 dari 6 *dataset* dan tidak pernah menempati peringkat terakhir. Rentang $[-1, 1]$ -nya mempertahankan nilai nol dan pola *sparsity*, menjadikannya kandidat kuat untuk sistem produksi.

***Robust Scaling* dan *Quantile* setara secara statistik** ($p = 0,596$), keduanya berada di bawah *scaler* linear. Hal ini mengindikasikan bahwa ketahanan terhadap pencilan saja tidak mencukupi—pemeliharaan struktur jarak relatif lebih penting untuk klasifikator yang diuji.

5 Pembahasan

5.1 Sintesis

Ketiga pertanyaan penelitian, jika dipandang secara bersama-sama, memberikan gambaran yang konsisten:

Penskalaan selalu membantu, dan *Z-Score* adalah default teraman—namun margin-nya kecil. Hasil agregat ($Z\text{-Score} \approx \text{Min-Max} > \text{MaxAbs} > \text{Robust} \approx \text{Quantile} > \text{Mentah}$) menyediakan titik awal, namun selisih sempit berarti bahwa pertimbangan spesifik-domain, ukuran *dataset*, dan struktur multikelas seringkali lebih berpengaruh daripada peringkat global.

Dasar teoretis untuk interaksi ini jelas. Klasifikator berbasis jarak menghitung besaran geometris yang terdistorsi oleh skala fitur yang tidak setara—metode penskalaan linear apa pun yang menyelaraskan rentang fitur dapat mengatasinya. *Z-Score* mempertahankan jarak relatif di bawah pencilan lebih baik daripada *Min-Max* karena tidak membatasi rentang hasil transformasi. *MaxAbs* menyediakan titik tengah dengan rentang $[-1, 1]$ -nya yang menghindari masalah pemampatan pencilan pada *Min-Max*.

5.2 Rekomendasi Praktis

Berdasarkan sintesis di atas, kami mengusulkan kerangka keputusan berikut:

Gunakan Standardisasi *Z-Score* ketika:

- Data mengandung fitur dengan distribusi yang tidak diketahui atau campuran.
- *Dataset* memiliki pencilan signifikan (medis, finansial, biologis).
- Permasalahan bersifat multikelas dengan batas kelas yang tumpang tindih.
- Diperlukan *default* yang aman ketika pengetahuan domain tidak tersedia.

Gunakan Normalisasi *Min-Max* atau *MaxAbs Scaling* ketika:

- Fitur memiliki batas alami yang diketahui (pembacaan sensor, pengukuran kimia).
- Mempertahankan *sparsity* penting (*MaxAbs* lebih disukai).
- *Dataset* berdimensi tinggi dengan kelas seimbang.

Gunakan *Robust Scaling* atau *Quantile Transformation* ketika:

- Terdapat pencilan ekstrem dan *scaler* linear gagal.
- Catatan: ekspektasi kinerja setara dengan—tidak lebih baik dari— *Z-Score*.

Lewati penskalaan ketika:

- Fitur-fitur sudah berada dalam skala yang serupa (data piksel, survei *Likert*).
- Klasifikator berbasis pohon (peningkatan dapat diabaikan).
- Diperlukan perbandingan *baseline*.

5.3 Perbandingan dengan Penelitian Terdahulu

Temuan kami sejalan dengan dan memperluas studi komparatif sebelumnya, khususnya de Amorim dkk. [18] dan Demircioglu [14]. Henderi dkk. [11] menemukan *Min-Max* lebih unggul pada klasifikasi kanker payudara dengan *k-NN*—kami mengonfirmasi hal ini untuk *k-NN* namun menunjukkan bahwa *Z-Score* melampaui *Min-Max* ketika klasifikatornya adalah SVM dan ketika evaluasi mencakup data multikelas. Pinheiro dkk. [9] menunjukkan bahwa metode ensemble kokoh terhadap penskalaan sementara SVM sangat sensitif; hasil kami mendukung temuan ini dan memperluasnya ke *MaxAbs Scaling*, yang bekerja kompetitif dengan *Z-Score* pada sebagian besar kombinasi klasifikator–*dataset*.

Sertifikasi *MaxAbs Scaling* dan *Quantile Transformation*—yang tidak ada dalam sebagian besar perbandingan sebelumnya [7, 11, 15, 16]—mengungkapkan bahwa *MaxAbs* merupakan alternatif yang viable terhadap *Min-Max*, khususnya pada data berdimensi tinggi.

5.4 Keterbatasan

- **Hiperparameter bawaan:** Tidak dilakukan penalaan hiperparameter di luar rentang k pada k -NN. Klasifikator yang dioptimalkan mungkin merespons penskalaan secara berbeda.
- **Cakupan dataset:** Enam *dataset* di empat domain memberikan keragaman yang memadai namun *dataset* tambahan akan memperkuat generalisabilitas.
- **Cakupan klasifikator:** *Deep learning*, *naive Bayes*, dan metode *gradient boosting* tidak dievaluasi.
- **Interaksi fitur:** Kami tidak meneliti interaksi antara penskalaan dan seleksi fitur atau reduksi dimensionalitas.

5.5 Penelitian Selanjutnya

Ekstensi yang mungkin meliputi:

- Perluasan ke *dataset* berdimensi tinggi (teks, genomika) dengan ribuan fitur.
- Penelitian interaksi dengan optimalisasi hiperparameter.
- Evaluasi pada arsitektur *deep learning* di mana penskalaan berinteraksi dengan fungsi aktivasi.
- Pengembangan sistem rekomendasi *scaler* otomatis berdasarkan meta-fitur *dataset*.

6 Kesimpulan

Studi ini mengevaluasi 3.384 konfigurasi klasifikator dengan validasi silang bertingkat 5-lipat (16.920 total pemasangan) yang membandingkan enam teknik penskalaan pada tujuh klasifikator dan enam *dataset* (termasuk empat *dataset* multikelas). Ketiga pertanyaan penelitian dijawab sebagai berikut:

RQ1 (peringkat keseluruhan): Standardisasi *Z-Score* menempati peringkat pertama (0,8561), setara secara statistik dengan *Min-Max* (0,8530, $p = 0,123$) namun secara signifikan di depan *MaxAbs* (0,8506, $p = 0,002$). Semua *scaler* secara signifikan mengungguli data mentah ($p < 0,01$).

RQ2 (ketergantungan klasifikator): SVM (RBF) adalah yang paling sensitif terhadap penskalaan (+7,7% peningkatan), k -NN menunjukkan sensitivitas sedang (+4,6–6,0%), dan model berbasis pohon hampir invarian (<0,2%).

RQ3 (ketergantungan domain): *Z-Score* unggul pada data medis dan data biologis multikelas. *MaxAbs* unggul pada data berdimensi tinggi yang seimbang. Data mentah memadai

ketika fitur telah berskala alami. Hasil multikelas mengonfirmasi bahwa keunggulan *Z-Score* bersifat generalisasi di luar klasifikasi biner.

Temuan tambahan meliputi: (i) *MaxAbs Scaling* merupakan alternatif kuat terhadap *Min-Max*; (ii) *Quantile Transformation* berada di bawah *scaler* linear, mengindikasikan bahwa pemeliharaan jarak lebih penting daripada normalisasi distribusi; dan (iii) selisih antar teknik penskalaan kecil ($<0,8\%$ antara tiga teratas), menekankan bahwa pertimbangan spesifik-domain harus memandu pemilihan akhir.

Hasil ini menunjukkan bahwa pertanyaan “*scaler* mana yang terbaik?” tidak lengkap—pertanyaan praktisnya adalah “*scaler* mana yang terbaik untuk *klasifikator saya, data saya, dan tipe permasalahan saya*?” Kerangka keputusan pada Bagian 5.2 menyediakan jawaban praktis.

References

- [1] P. Cunningham and S. J. Delany. k-nearest neighbour classifiers - A tutorial. *ACM Comput. Surv.*, 54(6):1–25, 2021.
- [2] R. K. Halder, M. N. Uddin, M. A. Uddin, S. Aryal, and A. Khraisat. Enhancing k-nearest neighbor algorithm: a comprehensive review and performance analysis of modifications. *J. Big Data*, 11:113, 2024.
- [3] S. N. Bakri and L. S. Harahap. Analisis klasifikasi algoritma k-nearest neighbor (k-nn) pada struktur daerah di kota medan. *J. Ilmu Komput. dan Sist. Inf.*, 4(2):182–193, 2025.
- [4] Z. Sultana, A. Ferdousi, F. Tasnim, and L. Nahar. An improved k-nearest neighbor algorithm for pattern classification. *Int. J. Adv. Comput. Sci. Appl.*, 13(8), 2022.
- [5] M. M. Mutoffar, E. Retnoningsih, Y. L. Yasik, and Eliza. *Decoding Intelligence: Algoritma Machine Learning dalam Aksi dan Bisnis*. Pt Kimhsafi Alung Cipta, 2025.
- [6] A. Çetin and A. Büyüklü. Revisiting distance metrics in k-nearest neighbors algorithms: Implications for sovereign country credit rating assessments. *Thermal Science*, 28(2):1905–1915, 2024.
- [7] M. Pagan, M. Zarlis, and A. Candra. Investigating the impact of data scaling on the k-nearest neighbor algorithm. *Comput. Sci. Inf. Technol.*, 4(2):135–142, 2023.
- [8] R. Guido, S. Ferrisi, D. Lofaro, and D. Conforti. An overview on the advancements of support vector machine models in healthcare applications: A review. *Information*, 15(4):235, 2024.
- [9] A. C. P. L. F. Pinheiro, M. F. Oliveira, A. R. Silva, A. A. Saraiva, F. S. Souza, and W. D. Godoy. The impact of feature scaling in machine learning: Effects on regression and classification tasks. *IEEE Access*, 13:1–20, 2025.

- [10] M. M. Ahsan, M. A. P. Mahmud, P. K. Saha, K. D. Gupta, and Z. Siddique. Effect of data scaling methods on machine learning algorithms and model performance. *Technologies*, 9(3):52, 2021.
- [11] H. Henderi, T. Wahyuningsih, and E. Rahwanto. Comparison of min-max normalization and z-score normalization in the k-nearest neighbor (knn) algorithm to test the accuracy of types of breast cancer. *Int. J. Inform. Inf. Syst.*, 4(1):13–20, 2021.
- [12] J. Manurung, H. Saragih, M. A. Prabukusumo, and E. A. Firdaus. Optimizing the performance of the k-nearest neighbors algorithm using grid search and feature scaling. *J. Mandiri IT*, 14(2):260–268, 2025.
- [13] M. Templ. Enhancing precision in large-scale data analysis: An innovative robust imputation algorithm for managing outliers and missing values. *Mathematics*, 11(12):2729, 2023.
- [14] A. Demircioğlu. The effect of feature normalization methods in radiomics. *Insights Imaging*, 15:2, 2024.
- [15] M. R. Firmansyah and Y. P. Astuti. Stroke classification comparison with knn through standardization and normalization techniques. *Adv. Sustain. Sci. Eng. Technol.*, 6(1), 2024.
- [16] Y. Pristyanto, A. Sidauruk, and A. Nurmasani. Klasifikasi penyakit diabetes pada imbalanced class dataset menggunakan algoritme stacking. *J. MEDIA Inform. BUDIDARMA*, 6(1):287–293, 2022.
- [17] S. Bates, T. Hastie, and R. Tibshirani. Cross-validation: what does it estimate and how well does it do it? *J. Am. Stat. Assoc.*, 119(546):1434–1445, 2023.
- [18] L. B. V. de Amorim, G. D. C. Cavalcanti, and R. M. O. Cruz. The choice of scaling technique matters for classification performance. *Appl. Soft Comput.*, 133:109924, 2023.